

PARTE 5: RAG-MLP - TRANSFORMERS

Paso 1: Embedding de la palabra con su posición.

Query vector: ^{me preguntó de otros vectores} ~~vector~~ ^{de la misma} ~~vector~~ ^{de} ~~vector~~ ^{un vector} en particular

(La pregunta es un vector)

→ (menor dimension)

multidimensional matrix de parámetros por el embedding de la palabra

K matrix: ^{representa series of matrix}, smaller dimensional que después se hace el producto entre los dos vectores y si el valor es muy alto, se dice que correlacionan.

Después usamos softmax, para normalizar los valores, entre 0 y 1
masking: pero todos los valores a -∞ antes de aplicar softmax donde las palabras futuras ya no afectan a los de antes

Value matrix la multiplicamos por el embedding de una palabra y ese vector se lo sumamos al vector de la siguiente palabra

3 matrices Query Key Value

Multihthead attention, lo hacen en paralelo.

PARTE A: EL BLOQUE COMPLETO COMO DECODER

Frases:

1. "El banco agnanta -"

2. "El banco presta -"

Paso 1: Entrada $X = E + P$, una fila por token

1.

$$E_{\text{frase}} = \begin{bmatrix} \text{vector EL} \\ \text{vector Banco} \\ \text{vector de agnanta} \end{bmatrix}$$

$$P = \begin{bmatrix} \text{vector posición 0} \\ \text{vector posición 1} \\ \text{vector posición 2} \end{bmatrix}$$

$$X = E_{\text{frase}} + P$$

Hago embeddings de las palabras con posición

$$X_1 = \begin{matrix} & \text{Erfone} \\ \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 \end{pmatrix} & + & \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 2 \end{pmatrix} & \neq \end{matrix}$$

$$X = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 2 \end{pmatrix}$$

$$X_2 \leq \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 0 \\ 0 & 1 & 1 & 0 \end{pmatrix} + \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 2 \end{pmatrix} = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 2 \end{pmatrix}$$

2) Proyecciones $W \neq Wv = \text{Identidad}$

$$Q = \sum W_q, \quad K = \sum W_k, \quad V = \sum W_v$$

$$W_X = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}$$

$$Q_1 = \cancel{X_1} W_q \quad X_1 = X_1 W_k \quad V_1 = X_1 W_v$$

$$Q_1 = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 2 \end{pmatrix} \cdot \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix} = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 2 \end{pmatrix}$$

$$K_1 = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 2 \end{pmatrix} \cdot \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix} = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 2 & 1 & 0 & 0 \end{pmatrix}$$

$$Y_1 = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 2 \end{pmatrix} \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix} = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 2 \end{pmatrix}$$

$$Q_2 = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 2 \end{pmatrix} \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix} = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 2 \end{pmatrix}$$

~~$$K_2 = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 2 \end{pmatrix} \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix} =$$~~

$$K_2 = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 2 & 0 & 0 \end{pmatrix}$$

$$V_2 = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 2 \end{pmatrix} \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix} = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 2 \end{pmatrix}$$

3) Operadores

$$S = Q K^T$$

comparamos cada query con cada key con producto punto
"Elemento simétrico" uso Q_1 y K_1^T

$$K_1 = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 2 & 1 & 0 & 0 \end{pmatrix} \quad K_1^T = \begin{pmatrix} 0 & 1 & 2 \\ 0 & 1 & 1 \\ 0 & 0 & 0 \end{pmatrix} \quad Q_1 = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 2 \end{pmatrix}$$

$$S_1 = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 2 & 3 \\ 0 & 1 & 2 \end{pmatrix}$$

"El banco presta"

$$Q_2 = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 2 \end{pmatrix}$$

$$K_2 = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 2 & 0 & 0 \end{pmatrix} \quad K_2^T = \begin{pmatrix} 0 & 1 & 1 \\ 0 & 1 & 2 \\ 0 & 0 & 0 \end{pmatrix}$$

$$S_2 = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 2 & 3 \\ 0 & 1 & 2 \end{pmatrix}$$

cuanto más la query de cada palabra con la key
 query que me vienen

Key más interesantes para ver si de uno

4) escala $S/\sqrt{d}$ $d=4$

$$\frac{S_1}{\sqrt{4}} \rightarrow \frac{1}{2} \begin{pmatrix} 0 & 0 & 0 \\ 0 & 2 & 3 \\ 0 & 1 & 2 \end{pmatrix} = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 1 & 1.5 \\ 0 & 0.5 & 1 \end{pmatrix}$$

$$\frac{S_2}{\sqrt{4}} \rightarrow \frac{1}{2} \begin{pmatrix} 0 & 0 & 0 \\ 0 & 2 & 3 \\ 0 & 1 & 2 \end{pmatrix} = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 1 & 1.5 \\ 0 & 0.5 & 1 \end{pmatrix}$$

Determinamos los puntajes para que no van tan largos

5) máscara causal: poner $-\infty$ ~~de los primeros~~

donde un token sea de los primeros mismo
 uno de mas adelante que ya está

El primer vector

$$M_1 \Rightarrow \begin{pmatrix} 0 & -\infty & -\infty \\ 0 & 1 & -\infty \\ 0 & 0.5 & 1 \end{pmatrix}$$

La máscara causal impide
 que cada token use información
 de tokens que futuras. Así mismo
 recibe $-\infty$ y lo pasa a 0

El segundo vector

$$M_2 \Rightarrow \begin{pmatrix} 0 & -\infty & -\infty \\ 0 & 1 & -\infty \\ 0 & 0.5 & 1 \end{pmatrix}$$

6) matriz de atención $A = \text{softmax por fila}$

$$\text{softmax}(z)_i = \frac{e^{z_i}}{\sum_{j=1}^n e^{z_j}}$$

Fila 1 El $\begin{bmatrix} e^0, e^{-\infty}, e^{-\infty} \end{bmatrix} = (1, 0, 0)$

$$A_1 = (1/1, 0/1, 0/1)$$

Fila 2 = punto $\begin{bmatrix} e^0, e^1, e^{-\infty} \end{bmatrix} = (1, 2, 0)$

$$A_1(1, 0, 0)$$

$$A_2 = (0.269, 0.731, 0)$$

fila 3 = $(e^0, e^1, e^2) = (1, e^1, e^2)$

$A_3 = (0, 186, 0, 307, 0, 506)$

~~A como prestr~~
A como prestr $\begin{pmatrix} 1 & 0 & 0 \\ 0, 269 & 0, 731 & 0 \\ 0, 186 & 0, 307 & 0, 506 \end{pmatrix}$

A como prestr $\begin{pmatrix} 1 & 0 & 0 \\ 0, 269 & 0, 731 & 0 \\ 0, 186 & 0, 307 & 0, 506 \end{pmatrix}$

Donde se convierten los puntos en peso de interacción, los filas suman 1.

↓ como mirar a cada palabra.

7) mezcla AV y después la proporción de salida (A V) W₀

W₀ es identidad

$$Y = AVW_0$$

$$V = XW_v$$

W_v = text

$$Y = AV$$

"El como prestr"

$$A_1 V_1 = \begin{pmatrix} 1 & 0 & 0 \\ 0, 269 & 0, 731 & 0 \\ 0, 186 & 0, 307 & 0, 506 \end{pmatrix} \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 2 \end{pmatrix}$$

$$Y_1 = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 0, 269 & 0, 731 & 0 & 1 \\ 0, 186 & 0, 307 & 0, 506 & 1, 506 \end{pmatrix}$$

$$A_2 V_2 = \begin{pmatrix} 1 & 0 & 0 \\ 0, 269 & 0, 731 & 0 \\ 0, 186 & 0, 307 & 0, 506 \end{pmatrix} \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 2 \end{pmatrix}$$

$$Y_2 = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 0, 269 & 0, 731 & 0 & 1 \\ 0, 307 & 0, 614 & 0, 506 & 1, 506 \end{pmatrix}$$

Mezcla la información de las palabras según los pesos de atención, ~~se obtiene~~

Wv extrae mejor la info con los parámetros que tiene

A.V obtiene un nuevo vector con información mezclada de las posiciones permitidas.

8) Residual

$$Z = X + (A \cdot V) W_0$$

sumamos X para conservar la información original de cada palabra y le sumamos lo que obtuvimos de las demás mediante la atención

El banco siguiente:

$$Z_1 = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 0 & 1 & 2 \end{pmatrix} + \begin{pmatrix} 0 & 0 & 0 & 1 \\ 0.731 & 0.731 & 0 & 1 \\ 0.814 & 0.307 & 1.506 & 3.506 \end{pmatrix}$$

$$Z_1 \approx \begin{pmatrix} 0 & 0 & 0 & 2 \\ 1.731 & 1.731 & 0 & 2 \\ 1.814 & 0.307 & 1.506 & 3.506 \end{pmatrix}$$

El banco resto:

$$Z_2 \approx \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 2 \end{pmatrix} + \begin{pmatrix} 0 & 0 & 0 & 1 \\ 0.731 & 0.731 & 0 & 1 \\ 0.307 & 0.814 & 0.506 & 1.506 \end{pmatrix}$$

$$Z_2 \approx \begin{pmatrix} 0 & 0 & 0 & 2 \\ 1.731 & 1.731 & 0 & 2 \\ 0.307 & 1.814 & 1.506 & 3.506 \end{pmatrix}$$

9. Layer norm $LN(Z)$, fila por fila (media y varianza de cada fila es despreciable).

Normalizamos cada fila por separado

$$LN(Z) = \frac{Z - \mu}{\sigma}$$

NOTA

Fila 1: El, igual en das das praxes

$$z_1 = \langle 0, 0, 0, 2 \rangle$$

$$\mu \approx 0.500 \quad \sigma = \sqrt{0.750}$$

$$LN(z_1) = \frac{0.500}{\sqrt{0.750}} = \frac{(0, 0, 0, 2) \cdot 0.500}{\sqrt{0.750}}$$

$$(-0.577, -0.577, -0.577, 1.732)$$

Fila 2: lamo

$$z_2 \approx \langle 1.731, 1.731, 0, 2 \rangle$$

$$\mu \approx 1.366 \quad \sigma \approx 0.796$$

$$LN(z_2) \approx \langle 0.439, 0.439, -1.715, 0.797 \rangle$$

Fila 3: aguantu

$$z_3 \approx \langle 1.813, 0.307, 1.306, 3.306 \rangle$$

$$\mu \approx 1.783 \quad \sigma \approx 1.442$$

$$LN(z_3) \approx \langle 0.026, -1.292, -0.242, 1.507 \rangle$$

Fila 3: posta

$$z_4 \approx \langle 0.307, 1.813, 1.306, 3.306 \rangle$$

$$\mu \approx 1.783 \quad \sigma \approx 1.443$$

$$LN(z_4) = \langle -1.292, 0.026, -0.242, 1.507 \rangle$$

$$LN(z_{\text{aguantu}}) = \begin{pmatrix} -0.577 & -0.577 & -0.577 & 1.732 \\ 0.439 & 0.439 & -1.715 & 0.797 \\ 0.026 & -1.292 & -0.242 & 1.507 \end{pmatrix}$$

$$LN(z_{\text{resta}}) \approx \begin{pmatrix} -0.577 & -0.577 & -0.577 & 1.732 \\ 0.459 & 0.459 & -1.715 & 0.797 \\ -1.292 & 0.026 & -0.242 & 1.507 \end{pmatrix}$$

Esto nos permite tener los vectores una escala controlada media 0, varianza 1. Permite inventos mas faciles

10. Feed Forward

$$FFN = \text{Relu}(LN(z) W_1) W_2$$

$$W_1 = \begin{pmatrix} 1 & -1 & 0 & 0 \\ -1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix} \quad W_2 = \pm$$

1. Multiplicamos $LN(z)$, W_1

El banco suantera

$$LN(z_1) W_1 \approx \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 1.318 & -1.318 & 0 & 0 \end{pmatrix}$$

El banco presta

$$LN(z_2) W_1 \approx \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ -1.318 & 1.318 & 0 & 0 \end{pmatrix}$$

2. Aplicamos Relu

$$\text{Relu}(x) = \max(0, x)$$

los negativos pasan a 0 los demas quedan igual

3. multiplicamos por W_2 , no cambia nada

$$FFN_{\text{suantea}} \approx \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 1.318 & 0 & 0 & 0 \end{pmatrix}$$

$$FFN_{\text{presta}} = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 1.318 & 0 & 0 \end{pmatrix}$$

Definimos una transformación de los componentes, agregando una operación no lineal mediante ReLU. Esto permite procesar la información y aprender patrones más complejos de los vectores.

11) Residual $H = Z + FFN$

Sumamos el resultado de feed forward a Z

El nuevo $H_{aguantu}$:

$$H_{aguantu} \approx \begin{pmatrix} 0 & 0 & 0 & 2 \\ 1.731 & 1.731 & 0 & 2 \\ 3.132 & 0.307 & 1.506 & 3.506 \end{pmatrix}$$

El nuevo H_{resta} :

$$H_{resta} \approx \begin{pmatrix} 0 & 0 & 0 & 2 \\ 1.731 & 1.731 & 0 & 2 \\ 0.307 & 3.132 & 1.506 & 3.506 \end{pmatrix}$$

Esto permite sumarle a los vectores con la información, más la que aprendió en el feed-forward de los patrones.

12) Layer Norm. normalizamos H

misma cosa que en 9 pero con estas matrices que salieron en el paso 11, mismo objetivo

$$LN(H_{aguantu}) \approx \begin{pmatrix} -0.377 & -0.377 & -0.377 & 1.732 \\ 0.459 & 0.459 & -1.715 & 0.797 \\ 0.793 & -1.403 & -0.472 & 1.084 \end{pmatrix}$$

$$LN(H_{resta}) \approx \begin{pmatrix} -0.377 & -0.377 & -0.377 & 1.732 \\ 0.459 & 0.459 & -1.715 & 0.797 \\ -1.403 & 0.793 & -0.472 & 1.084 \end{pmatrix}$$

73) Predicción: Predecir la siguiente palabra-

$$LN(H) = \text{hilo} \cdot W_{out}$$

Tomamos el vector final de la última palabra, que incorpora el contexto y lo multiplicamos por W_{out} para obtener un puntaje por palabra posible. softmax convierte esas probabilidades en 0 y 1 que suman 1. (Elegimos la palabra con mayor probabilidad).

el banco aguenta;

$$h_{W_{out}} = \langle 0, 0, -0.472, -0.472, 7.585, -2.816 \rangle$$

aplicamos softmax

$$f(x) = \frac{e^{x_i}}{\sum_{j=1}^n e^{x_j}}$$

$$\text{Prob aguenta} \langle 0.122, 0.122, 0.076, 0.076, 0.546, 0.007 \rangle$$

El banco presta:

$$\text{logits} = h_{W_{out}} = \langle 0, 0, -0.472, -0.472, -2.816, 7.585 \rangle$$

hilo softmax

$$\text{Prob presta} \langle 0.122, 0.122, 0.076, 0.076, 0.007, 0.596 \rangle$$

Elegimos la palabra de mayor probabilidad:

El banco aguenta pero, con 59.6%

El banco presta dinero, con el 59.6%

Parte B: Sin máscara causal

Retomamos matrices past y, no ponemos -∞

$$\text{Matriz frases} = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 1 & \frac{3}{2} \\ 0 & \frac{1}{2} & 1 \end{pmatrix}$$

NOTA

6) Optimal por frase

$$A \text{ para las dos frases} = \begin{pmatrix} 0.333 & 0.333 & 0.333 \\ 0.122 & 0.331 & 0.547 \\ 0.186 & 0.307 & 0.506 \end{pmatrix}$$

cada palabra incorpora información de todas las palabras de la frase, tanto anteriores, como posteriores

Ejemplo: se usa para entender un texto completo. RAB-

7. Mezcla $(A, V) W_0$ $W_0 = I$

$$A \cdot V \approx \begin{pmatrix} 0.667 & 0.333 & 0.333 & 1.333 \\ 0.878 & 0.331 & 0.547 & 1.547 \\ 0.814 & 0.307 & 0.506 & 1.506 \end{pmatrix}$$

Analizando el contenido, o sea que información se le da a cada palabra de cada palabra.

$V \cdot W_0$ se multiplica por una matriz para extraer mejor la información de las palabras textuales.

Después A que tiene las proporciones de impeto de cada palabra con cada palabra. Al multiplicar por V pasando todas las ponderaciones de como se relacionan entre las palabras a cada palabra, con la información mezclada, y como son los sectores que representan esa palabra literal.

8) Residual

$$Z = X + (A \cdot V) W_0$$

El como aguenta:

$$Z \text{ aguenta} \approx \begin{pmatrix} 0.667 & 0.333 & 0.333 & 2.333 \\ 1.878 & 1.331 & 0.547 & 2.547 \\ 1.814 & 0.367 & 1.506 & 3.506 \end{pmatrix}$$

El banco presta

$$Z_{\text{presta}} = \begin{pmatrix} 0.333 & 0.667 & 0.333 & 2.333 \\ 1.333 & 1.878 & 0.547 & 2.547 \\ 0.307 & 1.814 & 1.506 & 3.506 \end{pmatrix}$$

La suma de la información mezclada con cada palabra vectorizada (embedding), se le pasa a un modelo de red neuronal para que evalúe la intención de quien usó esa palabra. (le agregamos contexto).

9) Normalización $LN(Z) = \frac{Z - \mu}{\sigma}$

$$LN(Z_{\text{aguenta}}) = \begin{pmatrix} -0.302 & -0.704 & -0.704 & 1.709 \\ 0.412 & -0.333 & -1.403 & 1.323 \\ 0.026 & -1.292 & -0.292 & 1.507 \end{pmatrix}$$

$$LN(Z_{\text{presta}}) \approx \begin{pmatrix} -0.704 & -0.302 & -0.704 & 1.709 \\ -0.333 & 0.412 & -1.403 & 1.323 \\ -1.292 & 0.026 & -0.292 & 1.507 \end{pmatrix}$$

Filas de banco

con aguenta $\langle 0.412, -0.333, -1.403, 1.323 \rangle$
 con presta $\langle -0.333, 0.412, -1.403, 1.323 \rangle$

Controlamos la escala de los vectores, permite entender entre ellos lo que están dispersos y cercanos.

1) Comparamos la fila de banco $LN(Z)$ entre las dos frases la parte A y parte B

En la parte B cambia: con aguenta la fila banco es $\langle 0.412, -0.333, -1.403, 1.323 \rangle$ y con presta es $\langle -0.333, 0.412, -1.403, 1.323 \rangle$

Así mismo puede incorporar información del verbo o sea ver palabras banco adelante y no solo tener otros de la oración como en la parte A.

NOTA

2) En la parte A como sabe el modelo si tiene que predecir peso o dinero, si el vector de tokens es el mismo en las dos frases

La predicción usa el vector de la última posición de la oración, ~~correspondiente~~ que son aguantar y presta, más el del token. Ese vector incorpora el contexto y es diferente entre las frases. El multilenguaje por Word2Vec las probabilidades y favorece a peso o dinero.

3) La predicción de la parte A es lo que resultaría de la parte B para la última posición con iguales o distintas? Explique por qué con lo que hace la máscara.

Serían iguales para cada frase, en la última posición no hay tokens futuros para bloquear, por lo que la atención es igual con y sin máscara. Igual es justo en este ejercicio con mas capas puede cambiar. Como las operaciones posteriores actúan por fila, el resultado final también sería igual en este bloque.

4) ¿Qué modelos de la clase se parecen a la parte A y cuál a la parte B? ¿Para qué se usa cada uno?

Parte A: Se parece a un decoder como GPT, y lo que usan los LLMs para predecir el siguiente token/salida.

Parte B: A un encoder como BERT, que usa contexto de ambos lados para representar y analizar tokens.

5) ~~La predicción de la parte A es lo que resultaría de la parte B para la última posición con iguales o distintas?~~

¿Si P fuera todos ceros (que cambiaría en los resultados de este ejercicio? ¿y en una frase donde el orden cambia el sentido) de los tokens?

Si P fuera todos ceros perdería la información explícita de la posición. Eso cambiaría los vectores de entrada y los cálculos de después.

En la parte A se conserva cierta información de orden, aunque se quite P. Predicciones invariantes si el orden importa.